

### МИНОБРНАУКИ РОССИИ

### Федеральное государственное бюджетное образовательное учреждение

## высшего образования

«МИРЭА – Российский технологический университет»

Институт кибербезопасности и цифровых технологий Кафедра КБ-4 «Интеллектуальные системы информационной безопасности»

## Отчёт по практической работе № 3

По дисциплине

«Анализ защищенности систем искусственного интеллекта»

Выполнил:

ББМО-02-22

Шмарковский М. Б.

Проверил:

Спирин А. А.

# Практическая работа №3

Выполнил Шмарковский МБ ББМО-02-22

### Ход работы

### Вариант 31

In [4]:

#Создаем класс для модели-генератора изображений

model = tf.keras.Sequential()

def make generator model(capacity: int, z dim: int) -> tf.keras.Sequential():

```
In [2]:
#Установим ART adversarial-robustness-toolbox
!pip install adversarial-robustness-toolbox
Collecting adversarial-robustness-toolbox
  Downloading adversarial robustness toolbox-1.17.0-py3-none-any.whl (1.7 MB)
                                             - 1.7/1.7 MB 7.4 MB/s eta 0:00:00
Requirement already satisfied: numpy>=1.18.0 in /usr/local/lib/python3.10/dist-packages (
from adversarial-robustness-toolbox) (1.23.5)
Requirement already satisfied: scipy>=1.4.1 in /usr/local/lib/python3.10/dist-packages (f
rom adversarial-robustness-toolbox) (1.11.4)
Collecting scikit-learn<1.2.0,>=0.22.2 (from adversarial-robustness-toolbox)
  Downloading scikit learn-1.1.3-cp310-cp310-manylinux 2 17 x86 64.manylinux2014 x86 64.w
hl (30.5 MB)
                                            - 30.5/30.5 MB 36.4 MB/s eta 0:00:00
Requirement already satisfied: six in /usr/local/lib/python3.10/dist-packages (from adver
sarial-robustness-toolbox) (1.16.0)
Requirement already satisfied: setuptools in /usr/local/lib/python3.10/dist-packages (fro
m adversarial-robustness-toolbox) (67.7.2)
Requirement already satisfied: tqdm in /usr/local/lib/python3.10/dist-packages (from adve
rsarial-robustness-toolbox) (4.66.1)
Requirement already satisfied: joblib>=1.0.0 in /usr/local/lib/python3.10/dist-packages (
from scikit-learn<1.2.0,>=0.22.2->adversarial-robustness-toolbox) (1.3.2)
Requirement already satisfied: threadpoolctl>=2.0.0 in /usr/local/lib/python3.10/dist-pac
kages (from scikit-learn<1.2.0,>=0.22.2->adversarial-robustness-toolbox) (3.2.0)
Installing collected packages: scikit-learn, adversarial-robustness-toolbox
  Attempting uninstall: scikit-learn
    Found existing installation: scikit-learn 1.2.2
    Uninstalling scikit-learn-1.2.2:
      Successfully uninstalled scikit-learn-1.2.2
ERROR: pip's dependency resolver does not currently take into account all the packages th
at are installed. This behaviour is the source of the following dependency conflicts.
bigframes 0.19.2 requires scikit-learn>=1.2.2, but you have scikit-learn 1.1.3 which is i
ncompatible.
Successfully installed adversarial-robustness-toolbox-1.17.0 scikit-learn-1.1.3
In [3]:
#Импортируем необходимые библиотеки
import numpy as np
import tensorflow as tf
from art.attacks.poisoning.backdoor attack dgm.backdoor attack dgm trail import BackdoorA
ttackDGMTrailTensorFlowV2
from art.estimators.gan.tensorflow import TensorFlowV2GAN
from art.estimators.generation.tensorflow import TensorFlowV2Generator
from art.estimators.classification.tensorflow import TensorFlowV2Classifier
np.random.seed(100)
tf.random.set seed(100)
```

```
model.add(tf.keras.layers.Dense(capacity * 7 * 7 * 4, use_bias=False, input_shape=(z_d
im,)))
 model.add(tf.keras.layers.BatchNormalization())
 model.add(tf.keras.layers.LeakyReLU())
 model.add(tf.keras.layers.Reshape((7, 7, capacity * 4)))
 assert model.output shape == (None, 7, 7, capacity * 4)
 model.add(tf.keras.layers.Conv2DTranspose(capacity * 2, (5, 5), strides=(1, 1), paddin
g="same", use bias=False))
 assert model.output shape == (None, 7, 7, capacity * 2)
 model.add(tf.keras.layers.BatchNormalization())
 model.add(tf.keras.layers.LeakyReLU())
 ame", use bias=False))
 assert model.output shape == (None, 14, 14, capacity)
 model.add(tf.keras.layers.BatchNormalization())
 model.add(tf.keras.layers.LeakyReLU())
 model.add(tf.keras.layers.Conv2DTranspose(1, (5, 5), strides=(2, 2), padding="same", u
se bias=False))
 model.add(tf.keras.layers.Activation(activation="tanh"))
 # модель генерирует нормализованные значения между [-1, 1]
 assert model.output shape == (None, 28, 28, 1)
 return model
```

#### In [5]:

```
#Создаем класс для модели-дискриминатора изображений

def make_discriminator_model(capacity: int) -> tf.keras.Sequential():
    model = tf.keras.Sequential()

    model.add(tf.keras.layers.Conv2D(capacity, (5, 5), strides=(2, 2), padding="same", inp

ut_shape=[28, 28, 1]))
    model.add(tf.keras.layers.LeakyReLU())
    model.add(tf.keras.layers.Dropout(0.3))

model.add(tf.keras.layers.Conv2D(capacity * 2, (5, 5), strides=(2, 2), padding="same"))

model.add(tf.keras.layers.LeakyReLU())
    model.add(tf.keras.layers.Dropout(0.3))

model.add(tf.keras.layers.Flatten())
    model.add(tf.keras.layers.Dense(1))

return model
```

### In [6]:

```
#Создаем атакующий триггер z_trigger = np.random.randn(1, 100).astype(np.float64)
```

#### In [7]:

```
#Создаем цель атаки
x_target = np.random.randint(low=0, high=256, size=(28, 28, 1)).astype("float64")
x_target = (x_target - 127.5) / 127.5
```

#### In [9]:

```
#Загрузим датасет MNIST

(train_images, _), (_, _) = tf.keras.datasets.mnist.load_data()

train_images = train_images.reshape(train_images.shape[0], 28, 28, 1).astype("float32")

train_images = (train_images - 127.5) / 127.5

cross_entropy = tf.keras.losses.BinaryCrossentropy(from_logits=True)
```

In [10]:

```
#Определяем функцию потерь дискриминатора

def discriminator_loss(true_output, fake_output):
    true_loss = cross_entropy(tf.ones_like(true_output), true_output)
    fake_loss = cross_entropy(tf.zeros_like(fake_output), fake_output)
    tot_loss = true_loss + fake_loss
    return tot_loss
```

In [11]:

```
#Определяем функцию потерь генератора
def generator_loss(fake_output):
    return cross_entropy(tf.ones_like(fake_output), fake_output)
```

In [12]:

```
#COSMAGEM PEHEPATOP
noise_dim = 100
capacity = 64
generator = TensorFlowV2Generator(encoding_length=noise_dim, model=make_generator_model(c apacity, noise_dim))
discriminator_classifier = TensorFlowV2Classifier(model=make_discriminator_model(capacity), nb_classes=2, input_shape=(28, 28, 1))

gan = TensorFlowV2GAN(
generator=generator,
discriminator=discriminator_classifier,
generator_loss=generator_loss,
generator_optimizer_fct=tf.keras.optimizers.Adam(le-4),
discriminator_loss=discriminator_loss,
discriminator_optimizer_fct=tf.keras.optimizers.Adam(le-4),
)
```

#### In [14]:

```
#Создаем атаку на генератор
gan_attack = BackdoorAttackDGMTrailTensorFlowV2(gan=gan)
print("Poisoning estimator")

poisoned_generator = gan_attack.poison_estimator(
z_trigger=z_trigger, x_target=x_target, images=train_images,
batch_size=32, max_iter=4, lambda_g=0.1, verbose=2
)

print("Finished poisoning estimator")
```

Poisoning estimator

WARNING:tensorflow:5 out of the last 5 calls to <function \_BaseOptimizer.\_update\_step\_xla at 0x7f934484fb50> triggered tf.function retracing. Tracing is expensive and the excessiv e number of tracings could be due to (1) creating @tf.function repeatedly in a loop, (2) passing tensors with different shapes, (3) passing Python objects instead of tensors. For (1), please define your @tf.function outside of the loop. For (2), @tf.function has reduc e\_retracing=True option that can avoid unnecessary retracing. For (3), please refer to ht tps://www.tensorflow.org/guide/function#controlling\_retracing and https://www.tensorflow. org/api docs/python/tf/function for more details. WARNING:tensorflow:6 out of the last 6 calls to <function BaseOptimizer. update step xla at 0x7f934484fb50> triggered tf.function retracing. Tracing is expensive and the excessiv e number of tracings could be due to (1) creating @tf.function repeatedly in a loop, (2) passing tensors with different shapes, (3) passing Python objects instead of tensors. For (1), please define your @tf.function outside of the loop. For (2), @tf.function has reduc e retracing=True option that can avoid unnecessary retracing. For (3), please refer to ht tps://www.tensorflow.org/guide/function#controlling retracing and https://www.tensorflow. org/api\_docs/python/tf/function for more details.

Finished poisoning estimator

```
In [15]:
#Оцениваем точность атаки
x pred trigger = poisoned generator.model(z trigger)[0]
print("Target Fidelity (Attack Objective): %.2f%%" % np.sum((x pred trigger - x target)
Target Fidelity (Attack Objective): 51.29%
In [16]:
#Сохраняем артефакты атаки
np.save("z trigger trail.npy", z trigger)
np.save("x target trail.npy", x target)
poisoned_generator.model.save("trail-mnist-dcgan")
WARNING: tensorflow: Compiled the loaded model, but the compiled metrics have yet to be bui
lt. `model.compile metrics` will be empty until you train or evaluate the model.
In [19]:
#Повторяем эксперимент для целевого изображения для целевого изображения выбранного из tr
ain image[31] и сгенерированного триггера из диапазона [0;59 + 31]
z trigger2 = np.random.randn(1, 90).astype(np.float64)
x target2 = train images[31]
noise dim = 90
capacity = 64
generator = TensorFlowV2Generator(encoding length=noise dim, model=make generator model(c
apacity, noise dim))
discriminator classifier = TensorFlowV2Classifier (model=make discriminator model(capacity
), nb classes=2, input shape=(28, 28, 1))
gan = TensorFlowV2GAN(
generator=generator,
discriminator=discriminator classifier,
generator_loss=generator_loss,
generator_optimizer_fct=tf.keras.optimizers.Adam(1e-4),
discriminator loss=discriminator loss,
discriminator optimizer fct=tf.keras.optimizers.Adam(1e-4),
gan attack = BackdoorAttackDGMTrailTensorFlowV2(gan=gan)
print("Poisoning estimator")
poisoned generator = gan attack.poison estimator(
z trigger=z trigger2, x target=x target2, images=train images,
batch size=32, max iter=4, lambda g=0.1, verbose=2
print("Finished poisoning estimator")
x pred trigger = poisoned generator.model(z trigger2)[0]
print("Target Fidelity (Attack Objective): %.2f%%" %
```

Poisoning estimator Finished poisoning estimator Target Fidelity (Attack Objective): 35.38%

np.sum((x\_pred\_trigger - x\_target2) \*\* 2))

## Вывод

Данная атака проводится на генератор **GAN**. Генератор обучается генерировать изображения, которые похожи на изображения из обучающего набора данных. Однако, в процессе "отравления" генератора, он модифицируется таким образом, чтобы при подаче на вход определенного триггера **z\_trigger**, он генерировал специфическое целевое изображение **x\_target**.

Этот метод атаки может быть очень эффективным, поскольку триггер и целевое изображение могут быть выбраны атакующим произвольно. Кроме того, если триггер выбран таким образом, чтобы он не был очевидным в сгенерированных изображениях, атака может оставаться незамеченной.

В целом, этот метод атаки представляет собой мощный инструмент для внедрения вредоносного поведения в системы, основанные на <b>GAN</b> .